

Детекција на стрес со користење на методи од машинското учење

Марија Нецева 203/2016

Факултет за електротехника и информациски технологии (ФЕИТ)

Универзитет Св.Кирил и Методиј

Скопје, Република Северна Македонија

mneceva@gmail.com

GitHub: https://github.com/MNeceva/BME_Stress_detection_ML

Анстракт - Стресот претставува емоција која се развива кај дадена единка како резултат на одредена ситуација на која е изложена/низ која поминува. Резултатот секогаш е пропратен со ослободување на хормони на стрес, како адреналин и кортизол, кои пак ја засилуваат надразливоста и силата на телото. Дополнително, како резултат на стрес, автономниот нервен систем (АНС) влијае на извршувањето на одредени физички процеси/активност на начин што предизвикува зголемена мускулна напнатост/тензија, промени во концентрацијата на единката, промени во бројот на срцеви отчукувања (анг. heart rate (HR)) и промени во срцевиот ритам (анг. heart rate variability (HRV)). Област на интерес на оваа проектна задача е детекција на стрес со користење на методи од машинското учење како и имплементација на автоматизиран МЛ (анг. autoML) пристап. Податоците врз кои се вршат испитувањата се добиени од уреди кои во себе содржат носливи сензори. Популарноста на ваквите уреди расте од ден на ден, со што се овозможува ефективен и брз начин на добивање физиолошки/биолошки сигнали во текот на целиот ден. Прашање на време е само кога ваквите технологии ќе го достигнат својот врв на распространетост и употреба, со што секоја единка ќе и се овозможи да носи свој „паметен, персонализиран доктор“ на својата рака.

Клучни зборови—стрес; детекција; АНС; срцев ритам; промени на срцев ритам; носливи сензори; биолошки/физиолошки сигнали; R-R интервали; машинско учење; автоматизирано машинско учење

I. ВОВЕД

Стресот како поим ја опфаќа и генерализира реакцијата на човековото тело кога тоа е изложено на одредена закана или притисок за извршување на одредено барање/задача. Пример за барања/задачи кои може да предизвикаат стрес се притисок на работното место, ненадејни или драстични промени во секојдневната рутина на дадена единка, траума предизвикана од немил настан итн. Иако постоењето на стресот на краток временски период може да има и позитивно влијание врз единката, т.е. да делува мотивирачки за извршување дадена задача, истиот има многу негативно влијание врз здравјето на истата доколку се задржи на подолг временски период. Постојаното присуство на стрес може да предизвика разни болести, срцеви нарушувања, зголемување на крвниот притисок, дијабетис, појава на одредени ментални нарушувања како

анксиозност или депресија. Свесноста на единката за постоењето на истиот е од големо значење, бидејќи на тој начин истата ќе може да превеме и некои противмерки за превенција, намалување и спречување на истиот. Некои од чекорите преку кои може да се постигне тоа се: анализа на настаните/факторите кои можеби довеле до негова појава, примена на редовна физичка активност, промена во начинот на исхрана, релаксација или пак себеопкружување со поединци кои имаат позитивно влијание на самата емоционална состојба на единката. И покрај сите овие техники мора да се утврди дека секоја поединец реагира и се справува со стресот на различен начин, па поради тоа не може да се најде еден унифициран/генерален метод за негова детекција и намалување. Но, носливите сензори како медиуми за добивање на физиолошки податоци поврзани со поединци и употребата на методи од машинското учење за нивна анализа се доста ветувачки за развојот на можен општо-прифатлив метод за детекција и превенција на стрес. Она што треба да се направи е да се искористи технолошкиот напредок на носливите сензори и нивната се поголема прифатеност со цел да се дизајнира единствено неинвазивно решение за добивање на биолошки сигнали и нивна прецизна анализа/интерпретација со употреба на методи од МЛ. На овој начин би се добила брза, точна, едноставна и релативно поевтина медицинска нега. Моделите кои досега се развиени за детекција на стрес главно се од обликот на персонализирани, специјализирани модели наменети за конкретна единка. Пристап на креирање на персонализирани модели е доста точен и ефективен, но може да биде премногу скап ако истиот се имплементира за потребите на поголеми претпријатија/установи со цел поголема грижа на своите вработени. Освен што ќе биде поскап, со оглед на тоа што за секој еден вработен ќе треба да се креира и тренира засебен модел, истиот ќе биде и временски позахтевен. За таа цел она што оваа проектна задача го нуди е генерализиран модел за детекција на стрес базиран на класификациски алгоритми од МЛ како и техника за автоматско МЛ, со која се постигнува автоматизација при изборот на најдобар модел. Сите овие методи и алгоритми се применуваат врз податочно множество со записи кои се состојат од телесни мерења спроведени врз разни

млади луѓе кои возат во стресни околина како сообраќаен метеж, автопати, често стојат на црвено светло, секако со присуство и на период со релаксација за да се создадат и записи кои укажуваат на нестресна состојба на испитаниците.

II. ПОЗАДИНА

A. Физиолошко мерење на стрес

Стресот претставува емоција која се развива кај дадена единка како резултат на одредена ситуација на која е изложена/низ која поминува. Резултатот секогаш е пропратен со ослободување на хормони на стрес, како адреналин и кортизол, кои пак ја засилуваат надразливоста и силата на телото. Дополнително, како резултат на стрес, автономниот нервен систем (АНС) влијае на извршувањето на одредени физички процеси/активност како што се зголемена мускулна напнатост/тензија, нагли промени во концентрацијата на единката, промени во бројот на срцеви отчукувања (анг. heart rate (HR)), промени во срцевиот ритам (анг. heart rate variability (HRV)) итн. Општо гледано, стресот може да се подели во три различни категории, и тоа:

- Акутен стрес,
- Епизоден акутен стрес,
- Хроничен стрес,

Акутниот стрес фактор се карактеризира со краткорочно надразнување по кое со намалување на влијанието на стрес-факторот, телото се враќа во својата нормална/рамнотежна состојба. Оваа категорија на стрес е онаа која ни е од интерес во оваа проектна задача.

B. Мерење на стрес преку GSR

GSR сензорите многу често се користат при мерењето на нивото на стрес кај поединци. Она што тие го мерат е нивото на отпорноста на кожата. Колку нивото на стрес кај единката е поголемо, толку повеќе се зголемува потењето, а се намалува отпорот. Но, и тука постои неможност за генерализација, поради тоа што многу често не може да се направи разлика дали моментот на потење е поврзан со стрес или само со обична физичка активност.

B. Срце

Основната задача на срцето е да извршува ритмичка контракција и впумпување на крвта во белите дробови со цел нејзино збогатување со кислород, како и нејзина дистрибуција до сите органи во телото со цел обезбедување на сите клетки со хранливи материи.


G. Следење на срцевата работа преку ЕКГ

Срцевата контракција се мери во однос на тоа како електричната струја протекува и се шири низ срцевиот мускул. Срцевиот мускул се контрахира со проток на електрична струја во мускулот, која е произведена од пејсмејкер клетките и специјализирано ткиво за

спроводливост кои го реполаризираат и деполаризираат срцевиот мускул со транспортирање на електрична енергија низ мускулот. Ваквата електрична активност вообичаено се мери преку електрокардиограм (ЕКГ). Уред со кој се врши ова мерење обезбедува временско-напонски графички приказ на срцевите отчукувања.

D. Структура на ЕКГ сигналот

ЕКГ сигналот се состои од различни фази кои се показатели за тоа како електричната енергија патува низ преткоморите и коморите и истовремено ги стимулира. ЕКГ сигналот е изграден од пет делови и тоа P бран, QRS комплекс, ST сегментот, T бран и U бран. Првите две фази се фази на активација за време на кои мускулите се деполаризираат. Преостанатите три фази се фази на рехабилитација каде мускулите се реполаризираат и ја означуваат состојбата на мирување на истите. Целосната структура е прикажана на сликата подолу.




Слика 1. Структура на ЕКГ сигнал

E. Мерење на промени во срцевиот ритам (HRV)

HRV претставува поим кој опфаќа поголемо множество на карактеристики добиени преку анализа на интервалите помеѓу две срцеви отчукувања (R-R интервали). Најчестата постапка за добивање на HRV е со анализа на електрокардиограм (ЕКГ сигнал), но, благодарение на развојот на технологиите истата може да се добие од сигналите детектирани со носливи уреди (кои во себе имаат вградени сензори) како на пример разни напредни фитнес траки и ластици кои поставени на градите ја мониторираат срцевата акција. Испитувањата успешно покажуваат голема поврзаност на промената во срцевиот ритам со мерките за мониторирање на стрес, рак, дијабетес, мелитус, проблеми со спиењето, тешкотии при регулирање на емоциите и многу повеќе. Оваа проекта задача, имаме за цел да го предвиди стресот од достапните податоците за HRV, добиени со користење на комерцијално носливи сензори и уреди.

R-R интервалот се мери во милисекунди и дава информација за временската должина на интервалот помеѓу две последователни срцеви отчукувања, т.е. пикови од QRS комплексот. Се користи за изведување на HRV.



Слика 2. R-R интервал

Промените во срцевиот ритам можат да се добијат како резултат на применетите временски и фреквенциски пресметки врз последователни R-R примероци/вредности. Најчесто користените мерки во временски и фреквенциски домен може да се видат во табелаите дадена во прилог.

Карактеристики во временски домен	
AVNN	Просечна вредност од сите NN интервали
SDNN	Стандардна девијација од сите NN интервали
SDANN	Стандардна девијација од просечната вредност на сите NN интервали во сите 5 минути сегменти од 24 часовното снимање
SDNNIDX	Средна вредност од стандардната девијација на сите NN интервали во сите 5 минути сегменти од 24 часовното снимање
rMSSD	Квадратен корен од средната вредност на разликите од квадратите помеѓу соседни NN интервали
pNN50	Разлика помеѓу два соседни NN интервали помала од 50ms изразено во проценти
Карактеристики во фреквенциски домен	
ULF	Ултра ниски фреквенции - Вкупна спектрална моќност од сите NN интервали до вредност од 0.003 Hz
VLF	Многу ниски фреквенции - Вкупна спектрална моќност од сите NN интервали помеѓу вредностите 0.003 и 0.04 Hz
LF	Ниски фреквенции - Вкупна спектрална моќност од сите NN интервали помеѓу вредностите 0.04 и 0.15 Hz
HF	Високи фреквенции - Вкупна спектрална моќност од сите NN интервали помеѓу вредностите 0.15 и 0.4 Hz
LF/HF	Однос на моќностите од ниски наспроти високи фреквенции

Табела 1. Карактеристики на сигналите во временски и фреквенциски домен

Мерките во фреквенциски домен обично се добиваат со примена на периодограмот на Ломб-Скегел, кој всушност претставува варијанта на Фуриевата трансформација. Алгоритмот на Ломб-Скегел е особено погоден за податоци со нееднаков број примероци, како што се и самите RR интервали. Генерализираната форма на равенката за периодограмот на Ломб-Скегел е дадена со равенката подолу, каде што A, B и T се произволни функции на фреквенцијата f и времето на набљудување.

$$P(f) = \frac{A^2}{2} \left(\sum_n g_n \cos(2\pi f[t_n - T]) \right)^2 + \frac{B^2}{2} \left(\sum_n g_n \sin(2\pi f[t_n - T]) \right)^2$$

Равенка 1.. Равенка за пресметување на периодограм на Ломб-Скегел

Ж. Начини за детекција и мерење на срцевата активност преку користење носливи сензори

PPG е неинвазивна технологија која користи извор на светлина и фотодетектор поставен на површината на кожата, со цел мерење на волуметриските варијации на циркулацијата на крвта. Работи на принцип на осветлување на кожата и мерење на промените во нејзината апсорпција на светлина. PPG обично се реализира со помош на диоди кои емитуваат светлина

(LED) врз кожата и фотомодетектор (фотодиода) за мерење на количината на светлина која преминува или се рефлектирана од кожата. Постојат два вида на PPG сензори, трансмисивни и рефлективни.

III. ПОДАТОЧНО МНОЖЕСТВО, НЕГОВА ПОДГОТОВКА И ОЗНАЧУВАЊЕ НА НЕГОВИТЕ ПОДАТОЦИ

Податоците искористени за тренирање и евалуација на моделот се добиени од проект спроведен во МИТ од страна на Хејли како дел од нејзината теза за докторски студии. Записите во податочното множество се состојат од телесни мерења спроведени врз разни млади луѓе кои се изложени на стресни сценарија како управување автомобил во сообраќаен метеж, возење по автопат, често стоење на црвено светло итн. Секако постојат и записи кои содржат периоди на релаксација со цел меѓу нив да има и такви записи кои укажуваат на помалку или воопшто стресна состојба на испитаниците. Целот податочно множество може да се најде на веб-страницата на Physionet организацијата.

A. Формат на податочното множество

Податочното множество е зачувано во специфичен physionet формат, и е поделено на 18 .dat датотеки и 18 .hea датотеки со придружни метаподатоци. Податоците се состојат од сигнали на ЕКГ, ЕМГ, GSR мерења од стапалата, GSR мерења од рака, мерења на срцевиот ритам и мерења поврзани со респирацијата. Сите вредности се децимални, со фреквенција на семплирање/земање примероци од 15.5 примероци во секунда. За да можеме да работиме со вака форматираното податочно множество, користиме алатка од Physionet наречена WFDB со цел претварање на .dat, .hea датотеките во текстуални датотеки одделени со запирка со имиња на колони. Понатаму, варијабилноста на срцевиот ритам се добива од RR интервалите со примена на специјално креирана скрипта во програмскиот јазик Пајтон. Поконкретно варијабилноста на срцевиот ритам се пресметува со примена на лизгачки прозорец од 20 секунди врз два соседни RR интервали, и десет примероци од RR интервалот од претходниот прозорец плус пет примероци од RR интервалот од следниот прозорец. Ова резултира во прозорци што се преклопува во текот на времето со вкупна големина од околу 30 секунди. На тој начин се овозможува задржување на континуитетот на сигналот. Со ваквиот пристап се овозможува вклучување на настани од крајот и почетокот на прозорците, така што повеќе RR врвови се бројат при пресметување на карактеристиките на варијабилност на срцевиот ритам, притоа добивајќи податочно множество кое има повеќе примероци во однос на она што би се добило ако прозорецот беше со должина од 30 секунди без преклопување. Добиеното податочно множество е зачувана како .csv датотека.

Б. Ознака/лабелирање на податоците

Оригиналните податоци не содржат директни ознаки за стрес, и поради тоа истите мора да бидат некако пресметани. Начинот на кој што се изведува тоа е со мерење на GSR сигналот од стапалото. Се користат мерења од стапалото бидејќи така добиените сигнали изгледаат почисто од сигналите добиени при мерења на рацете (веројатно предизвикани од поголемо движење на истите). Средната вредност од GSR сигналот се зема како гранична точка за да се утврдување на дали одредена единка е под стрес или не. Секоја вредност над средната вредност е означена како состојба на стрес, додека секоја вредност под средната вредност е означена како нормална, релаксирана состојба. На овој начин проблемот кој го разгледуваме се сведува на бинарна класификациска МЛ задача. На овој начин околу половина од податоците се категоризирани како стресна состојба, додека другата половина е категоризирана како нормална, релаксирана состојба.

IV. МЕТОДИ

Постапката за детекција на присуство на стрес кај поединци се врши со примена на следните чекори:

1. Анализа и формирање на податочно множество преку екстракција на карактеристики од R-R интервали,
2. Чистење и подготовка на податоци,
3. Отстранување, селекција на карактеристики, стандардизација на вредности и поделба на множества за тестирање и тренирање,
4. Креирање и тренирање на МЛ модели,
5. Тестирање и евалуација на МЛ моделите.

А. Чистење и подготовка на податоците

Најпрво се врши проверка на исправноста на лабелите за податоците, односно се проверува дали лабелите се целобројни вредности од 1(стрес) или 0 (опуштена состојба). Понатаму се врши пречистување на NaN, inf, -inf вредностите т.ш истите се заменуваат со нулта вредност. Колоните кои содржат вредности за срцевиот ритам, на местото на тие вредности добиваат средна вредност на срцевиот ритам. Дополнително истите се чистат со примена на усреднувачки филтер. Тоа е така со цел ефективно потиснување на можните грешки при добивање на вредностите.

Б. Отстранување, селекција на карактеристики, стандардизација на вредности и поделба на множества за тестирање и тренирање

GSR карактеристиките кои се користат за лабелирање/класификација на податоците, се отстрануваат, заедно со ЕКГ и ЕМГ податоците, бидејќи овие информации не можат лесно да се добијат од носливи уреди кои моментално се присутни на пазарот. Сегментот со ултра ниската фреквенција (ULF) е исто така отфрлен, бидејќи мнозинството вредности се нула, што веројатно се должи на кратките временски интервали. Исто така, информациите од групата со многу ниска

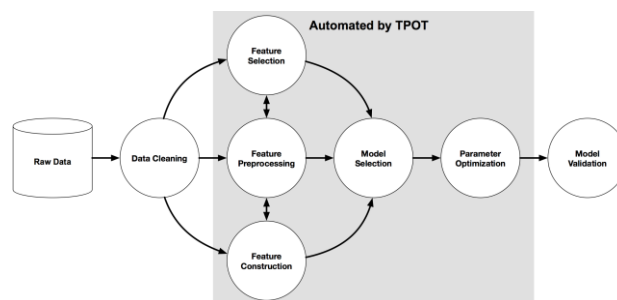
фреквенција (VLF) се отфрлаат бидејќи со повеќе истражувања е покажано дека многу нискиот фреквенциски е несигурна мерка во читањата под 5 минути и примероците што ги имаме во податочното множество не се многу конзистентни. Дополнително се отфрлаат карактеристиките добиени од PPG сигналот кои се поврзани со респирација. На крајот множеството карактеристики кои остануваат и се користат при тренирање на моделот се следните: HR, AVNN, RR интервали, SDNN, RMSSD, pNN50, TP, LF, HF, LFHF. Со ова вкупниот број на записи се сведува на 4132. За креирање на засебни множества за тренирање и тестирање на МЛ моделите, првобитното множество се дели во однос 80:20. Дополнително врз вредностите од податочното множество се врши стандардизација која подразбира нивно скалирање, т.ш нивната вкупна средна вредност изнесува 0, а стандардната девијација 1. Оваа постапка се прави поради постоењето на разноликост на самите вредности и потреба за нивно приближување.

В. Креирање и тренирање на МЛ модели

За добивање на најдобриот модел за детекција на стрес креирани се вкупно 11 модели од кои 5 се добиени со користење на избрани алгоритми за класификација со нивните дифолтни параметри, следните 5 се добиени со користење на истите алгоритми со тоа што сега нивните параметри се нагодени со користење на GradientSearch. Последниот 11ти модел е модел кој што е добиен со примена на автоматизирано МЛ.

• АВТОМАТИЗИРНО МАШИНСКО УЧЕЊЕ



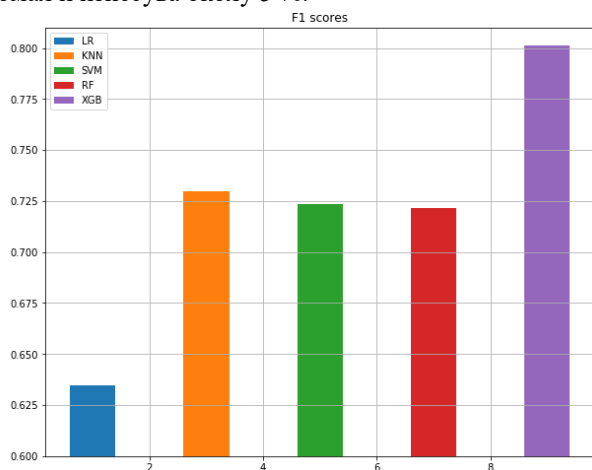
Имплементација на AutoML се базира на употреба на TPOT, автоматизирана алатка за машинско учење која ги оптимизира МЛ pipelines со помош на генетско програмирање. Во суштина, TPOT евалуира купче од модели со различни варијации на алгоритмите поточно нивните параметри. Само „најсилните“ алгоритми се оние кои преживуваат во една генерација. Ова функционира слично на природната селекција каде што преживуваат само најсилните видови и на крајот она што останува е најдобрата можна еволуција. TPOT може да има подолго време на извршување, но тоа е така поради големиот број на модели за евалуација и со цел на крај добивање најдобри можни резултати.



Слика 3. Имплементација на autoML-TPOT

Г. Тестирањ, резултати и евалуација на МЛ моделите

За метрика според која се одлучува кој модел е најдобар е одбрана да биде „F1_Score“. Изборот е направен врз основа на тоа што иако точноста како метрика е наједноста да се разбере, таа не секогаш може да е најсоодветниот избор за метрика за валидација, бидејќи истат може лесно да биде изманипулирана и нагодена да дава добри резултати за нешто што реално не е така. Наспроти точноста како метрика тука е F1_Score кој при вршење на пресметки во обсервација зема скоро сите добиени информации од предвидувањата како што се бројот на точно класифицирани и бројот на погрешно класифицирани позитивни и негативни записи, т.е. резултатот кој го дава е одреден баланс на сите нив. Освен F1_Score-от друго нешто кое би требало да не интересира, а би било пресудно при одредување на најдобар модел е бројот на грешно класифицирани записи како негативни, а всушност треба да се позитивни. Моделот е толку подобар колку што бројот на вака класифицирани записи е помал, првенствено поради тоа што станува збор за состојба која доколку не е навремено детектирана и третирана може да биде животозагрозувачка. Во конкретниот случај најдобри резултати даде XGBoost моделот, кој постигна F1_Score од 80% и содржи само 10% грешно класифицирани негативни записи кои треба да бидат позитивни. По него следуваат моделите добиени со помош на autoML-TPOT, со вредности за F1_Score-от од 79.86 % и 78.1 %. Процентот на грешно класифицирани записи тука е уште помал и изнесува околу 5 %.



Слика 4. Графички приказ за добиените резултати
а) F1_score на основни модели, б) F1_score на модели чии параметри се нагодени со GS, в) F1_score на сите модели

V. ЗАКЛУЧОК И ПОНАТАМОШНА РАБОТА

Овој проект нуди МЛ пристап за пронаоѓање на генерален модел кој ќе врши детекција на стрес преку анализа на информации поврзани со HRV, добиени од употреба на носливи уреди. Добиените резултати покажуваат дека HRV може да се вброи како една од поефективните метрики за откривање на стрес кај поединци. При тестирање на моделите врз податоци собрани од носливи сензори и искористување на информациите поврзани со движењето на испитаникот, а добиени од акцелерометарот, моделот многу често е способен да изврши правилна класификација за стресноста на одредена ситуација. Прецизноста со која се добиваат овие резултати може да биде до минута, секако тоа е возможно само со користење на HR, HRV и основните R-R интервали како влезни карактеристики во алгоритмите. Сепак, понекогаш може да има и потешкотии при извршување на ваквата класификација, но, тоа може да се препише на субјективната реакција на секој поединец кон дадена ситуација. За крај оваа проектна задача успешно го посочи потенцијалот кој го нуди спојувањето на моменталната технологија со МЛ со цел развивање на модели кои успешно би детектирале одреден недостаток или аномалија кај човекот како најсовршено живо суштество.

КОРИСТЕНА ЛИТЕРАТУРА

- [1] Stress detection with wearable devices and Machine Learning, <https://dataesspresso.com/en/2019/01/30/Stress-detection-with-wearable-devices-and-Machine-Learning/>
- [2] Heart Rate Variability: a (deep) primer, <https://www.hrv4training.com/blog/heart-rate-variability-a-primer>
- [3] Christopher André Ottesen, „ Investigating heart rate variability: a machine learning approach “, August 2017
- [4] Hotei: Stress Management Platform via Activity Recommendation, Tim Chan, Ryan Dowse, Akshay Garigiparthi, Sagar Patel, Nick Robertson
- [5] Kizito Nkurikiyeyezu, Anna Yokokubo, and Guillaume Lopez, The Effect of Person-Specific Biometrics in Improving Generic Stress Predictive Models, Wearable Environment and Information Systems Lab Aoyama Gakuin University 5-10-1 Fuchinobe Chuo-ku, Sagami-hara-shi, Kanagawa-ken 252-5258, Japan